

# 最終課題

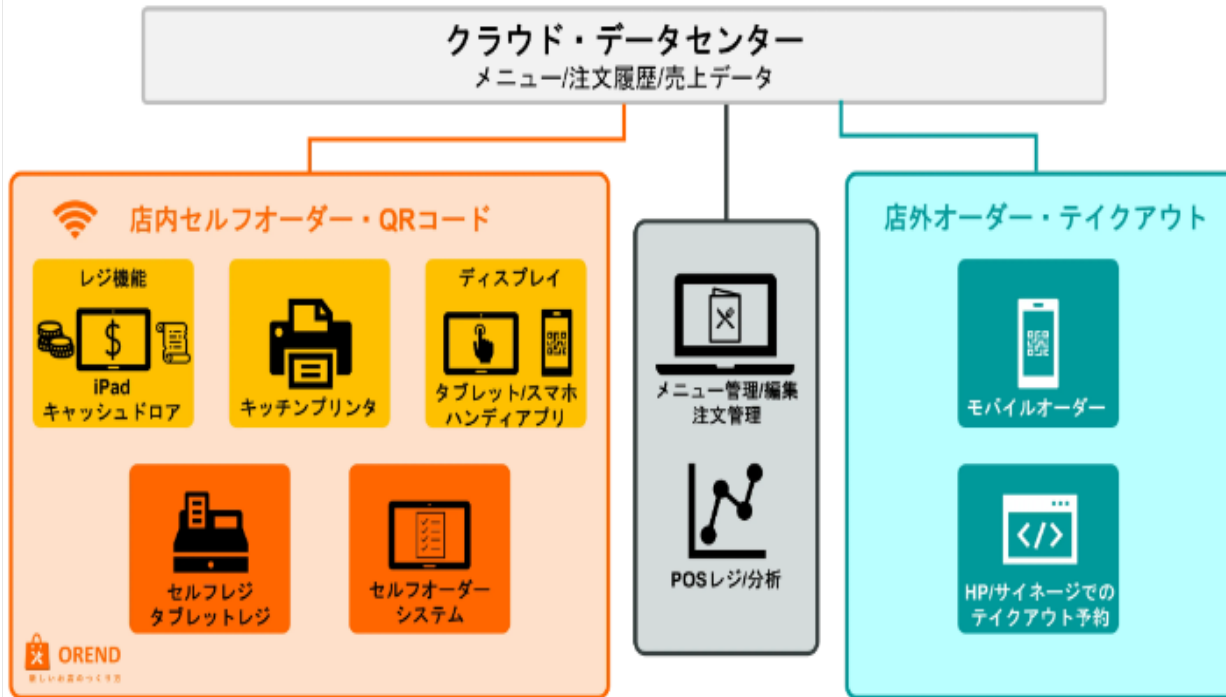
A社に関するご提案

# 目次

---

- 市場分析
- データの紹介と可視化
- モデルの予測
- 事業提案

# 市場の概要



## タブレット & タッチパネル注文・モバイルオーダーシステムの構成[1]

[1] <https://orend.jp/mag/a0289>

[2] <https://kigyolog.com/service.php?id=327#5-0>


[3] コールセンター白書2022

## オーダーエントリーシステムのメリット[2]

- 回転率向上
- 人的ミスの削減
- 管理業務の効率化

## オーダーエントリーシステムのデメリット

- 運用前にロールプレイングは必要
- 通信トラブルが発生する場合もある



## コールセンターの課題[3]

# 目次

---


- 市場分析
- データの紹介と可視化
- モデルの予測
- 事業提案

# データの紹介


- 複数のテーブルから構成されます。
- **擬似データ**です（実際のデータに近いです）。
- **2018.06.01から2020.03.31まで**、一日ごとの時系列データです(**n=670**)。
- 時間帯の中で、合計24ヶ月、96週です。
- 主な内容：

変数の内容	データ型と例	選考
日付	DATE型 (2018-06-01)	2018.06.01-2020.03.31
入電数(call)	整数型 (30)	単位：件
アカウント獲得数(account)	浮動小数点数 (1.0)	単位：件。標準化をしました
AirPAY CM放映フラグ(cm)	整数型 (0,1)	0：放映なし、1：放映あり
‘AirREGI’ワードの検索数(search)	整数型 (300)	GOOGLEでの検索数（毎週の総数）


# データの可視化とデータから見える課題




入電数



CM放映フラグ



アカウント獲得数



ワードの検索数

- 週ごとの合計数
- X軸の形式：年. 週


図によって：

- すべての変数はある程度の周期性を持っています。
- 2019年の第40週、すべての変数の数もピークになりました。
- 入電数の揮発性がより高いです。

- 研究問題：毎週の総入電数を予測します。

# 入電数の周期分解

- 入電数の時系列変化をよりよく観察するために、周期分解(STL分解)を行います：



- 長期的な変動では、緩やかな上昇の後、19.42付近でピークに達し、その後下降します。
- 5週間ほどの周期で、やや季節的な変化があります。
- 季節性やトレンドで説明できない残り(残差)に対して、変化が多くないです。
- 毎週の総入電数を予測するために、機械学習の手法が必要です。


# 目次

---

- 市場分析
- データの紹介と可視化
- モデルの予測
- 事業提案



# モデルの選択



## 自己相関の確定：

- Lag=5の場合、自己相関が存在します。
- つまり、 $Call(t)$ と $call(t-5)$ は関係があります。

## 定常性の判定：

- ADF検定を行います。
  - 定常：平均や分散が一定の時系列
1. そのまま測定すると：  
p値：0.225098(定常ではありません)
  2. 一次階差分を加えると  
p値：0.000000(定常と言えます)

## 選択したモデル：

- 一次階差分を含めるARIMAモデル

# モデルの紹介

- ARIMA(p,d,q):


$$y_t - y_{t-d} = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

$$y_t - y_{t-d} = c + \varepsilon_t + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{i=1}^q \theta_i \varepsilon_{t-i}$$

ARIMAモデルの成分	変数の表示	選考
<b>AR</b> (AutoRegressive)	p	過去のデータが未来のデータに影響を与える成分です
<b>I</b> (Integrated)	d	データの差分を取り、原系列が定常過程になるようにする成分です
<b>MA</b> (Moving Average)	q	過去の誤差項が未来のデータに影響を与える成分です。

- ARIMAモデルはトレンド、季節性、および他のパターンを捉えるのに適しており、予測や時系列データの解析に幅広く利用されています。

# モデルの実行と結果



ARIMAモデルで毎週ごとの入電総数を予測する結果

- AICの値を最小するために、何度の試行錯誤をしたあと、 $(p,d,q)=(5,1,2)$ を決定します。
  - 訓練データ：テストデータ = 86:10
  - テストデータは一番遅いの部分です。
- 
- 赤い部分：訓練データで予測する結果
  - 青い部分：元のデータ
- 
- モデルの予測結果は元のデータに似ています。

# 目次

---

- 市場分析
- データの紹介と可視化
- モデルの予測
- 事業提案

# 入電総数を予測するモデルの応用

- 今回のモデルは、1週間の入電総数をある程度予測することができます。

## 需要予測

- 将来の入電の傾向や需要の変動を理解し、適切なリソースやサービスの調整が可能となります。

## 資源管理

- 予測された入電数をもとに、スタッフのシフトやリソースの配置を最適化できます。

## サービスの最適化

- ピーク時にはサポートやカスタマーサービスの拡充を行い、顧客満足度を向上させることが可能です。

## 予算編成

- 予測を元に収益やコストを見積もり、予算を効果的に管理することが可能です。

# モデルの長期的なご提案

## 経済指標やイベントの 考慮

- 入電総数に影響を与える可能性のある経済指標や重要なイベントデータをモデルに取り入れることが重要です。
- これにより、外部環境の変化にも適応できます。

## フィードバックループの 設定

- 定期的なフィードバックを取り入れ、ユーザーのフィードバックや実際の結果をモデルに組み込んで改善する仕組みを構築します。

## 祝日情報の組み込み

- 入電総数に影響を与える可能性がある祝日情報を取り入れることで、予測モデルの精度向上が期待できます。

# 問題点と対策

モデル実行する結果によると、精度はそんな高くではないですので、モデルの修正が必要です。

## モデルの問題：

- 訓練データが86個あり、回帰分析において、季節変動を適切に捉えることが難しい状況です。
- 他の入電総数に与える影響の変数がモデルに含んでいません。
- 新しいデータや状況の変化に対応がありません。

## 問題に対する対策：

- より長時間のデータを探します。
- 他の変数(など)が入電総数に与える影響を研究します。
- データの処理、モデルの選択について、より効果的な手法を試します。また、定期的なモデルの評価を行い、必要に応じてモデルを再調整します。